

UCAS 模式识别-笔记 1-贝叶斯决策

一、统计模式识别分类

1.生成模型：基于概率密度的方法，利用参数估计或非参数估计求解概率密度，从而得到后验概率进行决策（基于贝叶斯决策理论）。不同类别分别学习。目标是得到每个类别的分布函数。

参数方法：假设数据的概率密度函数形式已知，根据训练集估计模型的参数。

代表：HMM/贝叶斯网络

非参数方法：不知道概率密度形式，直接根据数据估计概率密度函数。

代表：KNN/Parzen 窗

半参数法：GM，混合高斯知道参数的表达式形式，但是里面又有隐变量，不明确知道。

2.判别模型：没有假设概率密度函数形式，直接根据数据集学习后验概率、判别函数、决策面，得到的是判别信息。所有类别样本一起学习，找到类别之间的区别。目标是分类误差最小。

代表：神经网络、svm、决策树、boosting

3.混合模型：生成模型 + 判别学习

二、贝叶斯决策理论

1.最小错误率准则——最大后验概率准则

$$P(\omega_i | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_i)P(\omega_i)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | \omega_i)P(\omega_i)}{\sum_{j=1}^c p(\mathbf{x} | \omega_j)P(\omega_j)}$$

哪个类别的后验概率大，就判为哪个类。

2.最小风险准则——贝叶斯决策的一般形式，引入了代价函数

代价函数：真实类别为 ω_j ，判为第 α_i 类的代价。

$$\lambda_{ij} = \lambda(\alpha_i | \omega_j)$$

条件风险： x 判为第 i 类的总代价。注意这里，变量是 α_i ， x 已知，判为不同的类别，损失不一样。

$$R(\alpha_i | \mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x})$$

最小风险决策：看 x 判为哪一类的风险（损失）最小，就判定为哪一类。

$$\arg \min_i R(\alpha_i | x)$$

3.两者的关系：当最小风险准则中，代价函数是 0-1 函数时，两者是等价的。值得注意的是，当先验概率相等时，最大后验概率准则又和最大似然准则等价。

下面，就以两类分类的例子解释以上结论：

代价函数为 0-1 损失：

$$\lambda(\alpha_i | \omega_j) = \begin{cases} 0 & i = j \\ 1 & i \neq j \end{cases} \quad i, j = 1, \dots, c$$

条件风险展开求和如下：

$$\begin{aligned} R(\alpha_i | \mathbf{x}) &= \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x}) \\ &= \sum_{j \neq i} P(\omega_j | \mathbf{x}) \\ &= 1 - P(\omega_i | \mathbf{x}) \end{aligned}$$

所以， $R(\alpha_1 | x) = 1 - P(\omega_1 | x)$, $R(\alpha_2 | x) = 1 - P(\omega_2 | x)$ 。

根据最小风险决策是找到使得条件风险最小的 i ，即 $R(\alpha_1|x) < R(\alpha_2|x)$ ，则判为 w_1 。化简可得此时 $P(w_1|x) > P(w_2|x)$ ，这恰好是最大后验概率准则下的判决。
由此证明当代价函数为 0-1 损失时，两个决策原则等价。
进一步，我们根据贝叶斯公式对 $P(w_1|x) > P(w_2|x)$ 展开可得 $P(x|w_1)P(w_1) > P(x|w_2)P(w_2)$
当先验概率相等时，得到 $P(x|w_1) > P(x|w_2)$ ，即和最大似然准则等价。

4.推广：带拒识的决策

动机：在有的情况下，如果识别错误，代价会很大。这个时候，我们可以通过拒绝识别后，再交给人去处理，降低代价。

代价函数引入新的一类：

$$\lambda(\alpha_i | \omega_j) = \begin{cases} 0, & i = j \\ \lambda_s, & i \neq j \\ \lambda_r, & \text{reject} \end{cases}$$

求条件风险：

$$R_i(\mathbf{x}) = \begin{cases} \lambda_s [1 - P(\omega_i | \mathbf{x})], & i = 1, \dots, c \\ \lambda_r, & \text{reject} \end{cases}$$

根据最小风险准则决策：当拒识的风险比判错的风险小时，我就不判决了，直接拒识。否则我们就像之前一样找到 i 使得条件风险最小。

$$\arg \min_i R_i(\mathbf{x}) = \begin{cases} \arg \max_i P(\omega_i | \mathbf{x}), & \text{if } \max_i P(\omega_i | \mathbf{x}) > 1 - \lambda_r / \lambda_s \\ \text{reject}, & \text{otherwise} \end{cases}$$

三、判别函数和决策面——分类器的表示

1.定义

判别函数：表征每一类的广义似然度，哪个类的似然度越大，就判为哪一类。比如可以用后验概率。

决策面：两类判别函数相等的点的集合

2.高斯密度下的判别函数、决策面：如果协方差矩阵 $\Sigma_i = \sigma^2 \mathbf{I}$ 或者相等 $\Sigma_i = \Sigma$ ，则它的判别函数是线性判别函数(LDF)，如果协方差矩阵是任意的，则是二次判别函数(QDF)。

证明如下：

这里，我们采用 likelihood 作为判别函数：

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i)$$

其中，

$$p(\mathbf{x} | \omega_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu_i) \Sigma_i^{-1} (\mathbf{x} - \mu_i) \right]$$

根据协方差分为以下三种情况：

- Case 1: $\Sigma_i = \sigma^2 \mathbf{I}$

$$g_i(\mathbf{x}) = -\frac{\|\mathbf{x} - \mu_i\|^2}{2\sigma^2} + \ln P(\omega_i)$$

– Euclidean distance $\|x - \mu_i\|^2 = (x - \mu_i)^t(x - \mu_i)$

– 展开二次式 $(x - \mu_i)^t(x - \mu_i)$

$$g_i(x) = -\frac{1}{2\sigma^2}[x^t x - 2\mu_i^t x + \mu_i^t \mu_i] + \ln P(\omega_i)$$

– 忽略与类别无关项，得到线性判别函数

$$g_i(x) = w_i^t x + w_{i0}$$

$$w_i = \frac{1}{\sigma^2} \mu_i \quad w_{i0} = \frac{-1}{2\sigma^2} \mu_i^t \mu_i + \ln P(\omega_i)$$

– 二类决策面(判别函数相等的点构成)

$$g_i(x) = g_j(x)$$

$$\Rightarrow w^t(x - x_0) = 0 \quad w = \mu_i - \mu_j$$

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} (\mu_i - \mu_j)$$

• Case 2: $\Sigma_i = \Sigma$

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$

$$\Rightarrow g_i(x) = -\frac{1}{2}(x - \mu_i)^t \Sigma^{-1} (x - \mu_i) + \ln P(\omega_i)$$

– 展开二次式 $(x - \mu_i)^t \Sigma^{-1} (x - \mu_i)$

线性判别函数! $g_i(x) = w_i^t x + w_{i0}$

$$w_i = \Sigma^{-1} \mu_i \quad w_{i0} = -\frac{1}{2} \mu_i^t \Sigma^{-1} \mu_i + \ln P(\omega_i)$$

– 二类决策面 $g_i(x) = g_j(x)$

$$\Rightarrow w^t(x - x_0) = 0 \quad w = \Sigma^{-1}(\mu_i - \mu_j)$$

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\ln [P(\omega_i)/P(\omega_j)]}{(\mu_i - \mu_j)^t \Sigma^{-1} (\mu_i - \mu_j)} (\mu_i - \mu_j)$$

• 注意跟 $\mu_1 - \mu_2$ 的关系，决策面不一定与之垂直

• 当 $P(\omega_1) = P(\omega_2)$ ，决策面经过 $(\mu_1 + \mu_2)/2$

• Case 3: $\Sigma_i = \text{arbitrary}$

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$

$$g_i(x) = x^t W_i x + w_i^t x + w_{i0}$$

$$W_i = -\frac{1}{2} \Sigma_i^{-1} \quad w_i = \Sigma_i^{-1} \mu_i$$

$$w_{i0} = -\frac{1}{2} \mu_i^t \Sigma_i^{-1} \mu_i - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$

由此可以看到，当属于 case1/case2 时，判别函数为 LDF，case3 中，判别函数为 QDF。

